UTILISATION DU TALN POUR L'ANALYSE DE DOCUMENTS D'ARCHIVES MANUSCRITES : APPLICATION AUX REGISTRES DU THÉÂTRE DE LA COMÉDIE-ITALIENNE

MeetUp Machine Learning

Adeline GRANET

5 décembre 2016

LINA équipe TALN - IRCCyN équipe IVC Université de Nantes

PROJET CIRESFI

CONTEXTE POLITIQUE DU XVIII^e SIÈCLE

Chronologie de l'Opéra-Comique

1669 Louis XIV fonde l'Académie Royale de musique (Opéra).

1680 Louis XIV fonde la Comédie-Française et leur donne le *privilège* d'être les seuls lieux de représentations de la musique et du théâtre.

1697 Les comédiens italiens n'ont plus le droit de jouer et sont renvoyés de Paris.

1716 Le régent (Duc d'Orléans) autorise de nouveau les comédiens italiens à jouer à Paris.

⇒ Début des registres étudiés.

1762 Fusion de l'Opéra et de la Comédie-Italienne

1780 Interdiction de jouer en italien, la troupe reprend le nom d'Opéra-Comique.

1783 Déménagement dans le nouveau théâtre *Salle Favard* avec plus de 1100 places (aujourd'hui le *théâtre national de l'Opéra-Comique*)

1791-1793 Fin des privilèges et liberté des théâtres est proclamée ⇒ Fin des registres étudiés

2

Contrainte et Intégration : pour une Réévaluation des Spectacles Forains et Italiens sous l'Ancien Régime

 Contextualisation historico-politique : intégration jusqu'à l'obtention du privilège de l'Opéra;

- Contextualisation historico-politique : intégration jusqu'à l'obtention du privilège de l'Opéra;
- La contrainte comme moteur : révolution dans la forme du théâtre avec des nouveaux genres de pièces par écriteaux, monologues à plusieurs, pantomimes, opéra-comique;

- Contextualisation historico-politique : intégration jusqu'à l'obtention du privilège de l'Opéra;
- La contrainte comme moteur : révolution dans la forme du théâtre avec des nouveaux genres de pièces par écriteaux, monologues à plusieurs, pantomimes, opéra-comique;
- 3. L'économie des spectacles : retracer les coûts de production et organisation ;

- Contextualisation historico-politique : intégration jusqu'à l'obtention du privilège de l'Opéra;
- La contrainte comme moteur : révolution dans la forme du théâtre avec des nouveaux genres de pièces par écriteaux, monologues à plusieurs, pantomimes, opéra-comique;
- 3. L'économie des spectacles : retracer les coûts de production et organisation ;
- Exploration et analyse innovante : numérisation, extraction d'information, et indexation des informations contenus dans les ressources disponibles.

- Contextualisation historico-politique : intégration jusqu'à l'obtention du privilège de l'Opéra;
- La contrainte comme moteur : révolution dans la forme du théâtre avec des nouveaux genres de pièces par écriteaux, monologues à plusieurs, pantomimes, opéra-comique;
- 3. L'économie des spectacles : retracer les coûts de production et organisation ;
- Exploration et analyse innovante : numérisation, extraction d'information, et indexation des informations contenus dans les ressources disponibles.
- ⇒ Défi pluridisciplinaire : mettre la reconnaissance de l'écriture et le traitement du langage au service de l'Histoire

Projet CIRESFI

Les registres de la Comédie-Italienne

État de l'art : la reconnaissance de l'écriture

Prétraitement

Extraction des caractéristiques

Méthodes de reconnaissance de l'écriture

Traitement du langage

Identification des problèmes

Corpus et caractéristiques

Les corpus

Les features

Premiers tests et résultats

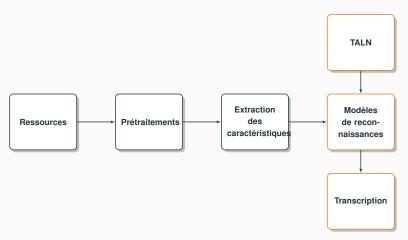


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures



ÉVOLUTION DES DOCUMENTS

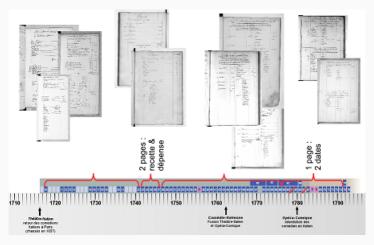
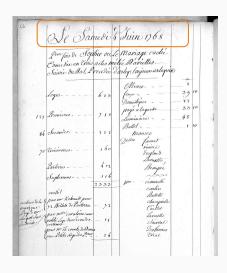


FIGURE – Frise reprenant l'ensemble des 63 registres par année et faisant mention de la forme utilisée sur la période 1717 à 1791.

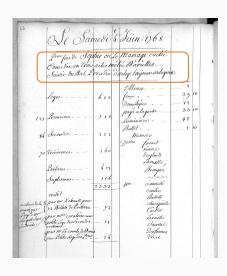
7

Date



Date

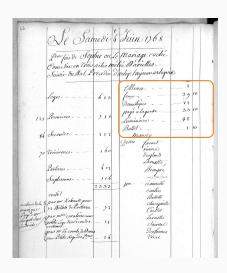
Titre



Date

Titre

Dépenses

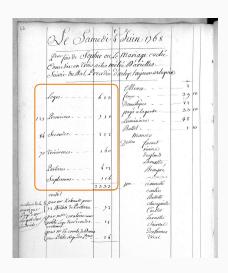


Date

Titre

Dépenses

Recettes



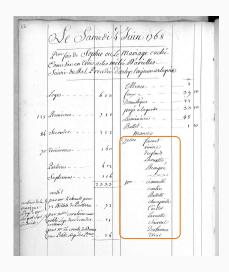
Date

Titre

Dépenses

Recettes

Acteurs



Date

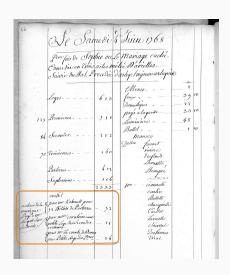
Titre

Dépenses

Recettes

Acteurs

Notes



Date

Titre

Dépenses

Recettes

Acteurs

Notes

Samedi	Juin 1	768		
Contine ou	Mariaar	cache.		
row neles M.	te Marut	110		
1. Avecedic	arley: loojee	u artiquis		
	Mine.		- 4	
- 623	faye ;			
100	port also	arti	33 10	
750	Luminary		48	
111	Ballet -	-	1 10	
	guin 1	want-		
160	2	ngland .		
40				
- 116		Low		
2333				
****		Butte		
Sec 22		Coulte		
wites eg				
Mary 16		Gaberna Trist		
	Sephie oc. 100 acts mo	Synthie ou. C. Maringe risk and a Meka Marine for a day make the grand 6 2 Section of Banky longing 6 2 Section of Banky longing 6 2 Section of Bank 1 3 2 Section of Bank 1 4 12 1 16 1 16 1 16 1 16 1 16 1 16 1 16 1	Company of the second of the s	Apple on the Maring and Apple of the Maring and Apple

Objectifs

Étiqueter et indexer automatiquement chaque champs des registres journaliers

Extraire les entités nommées des registres

DIFFICULTÉS DES REGISTRES I

- **Divers types de documents** : comptes journaliers, mensuels, annuels, état des pensionnaires, note volante, . . . ;
- **Mise en pages variée** : plusieurs jours sur une page, deux pages pour une journée, une page pour une journée;
- Différentes langues : italien, vénicien, français ;
- Plusieurs scripteurs : varie selon les registres ;
- **Disposition et informations changeantes** : mention des jours de relâche, de fermeture du théâtre, précision sur la pièce jouée dans le titre,

DIFFICULTÉS DES REGISTRES II

Études précédentes

Temps: 3 mois pour chercher 1 information (droit d'auteurs) dans chaque compte mensuel sur une période de 10 ans des registres;

Fiabilité : plusieurs transcriptions manuelles incomplètes et avec des interprétations.

Vocabulaire des titres basé sur Repertorio

de titres : 1055 ou 1182 (avec tous les titres d'une unique pièce)

de mots: 1359 (avec mots vides)

Les plus fréquents : Arlequin (197) (Arlequins(11), Arlequine(1), Arlequines(2)) ; amour (47) ; deux (31) ; Pantalon (23) ; amant (22) ; mariage (20) ; Scapin (16) ; amoureux (16) ;

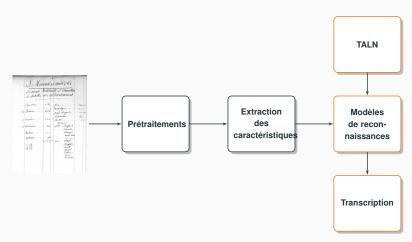


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures

ÉTAT	DE L'ART	: LA REC	CONNAISSA	NCE DE	L'ÉCRIT	URE

Conversion de l'image couleur RGB en niveaux de gris



Conversion de l'image couleur RGB en niveaux de gris

Suppression du fond de l'image par filtre gaussien



Conversion de l'image couleur RGB en niveaux de gris Suppression du fond de l'image par filtre gaussien

Binarisation de l'image avec la méthode de Otsu



Conversion de l'image couleur RGB en niveaux de gris Suppression du fond de l'image par filtre gaussien Binarisation de l'image avec la méthode de Otsu Classification des pixels pour extraire l'encre par CAE

Conversion de l'image couleur RGB en niveaux de gris Suppression du fond de l'image par filtre gaussien Binarisation de l'image avec la méthode de Otsu Classification des pixels pour extraire l'encre par CAE

Limites

- ⇒ Risques de perdre des pixels d'encre fondus dans le fond;
- ⇒ Contour du document dans l'image suivant la couleur peut influencer les différentes techniques

Les types de segmentation : bloc, ligne, mot

Les types de segmentation : bloc, ligne, mot

Les types de segmentation : bloc, ligne, mot

Segmentation en ligne par projection des pixels

Les types de segmentation : bloc, ligne, mot

Segmentation en ligne par projection des pixels

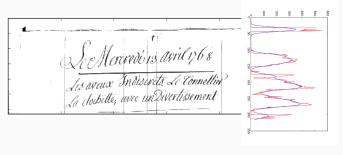


FIGURE - Projection de pixels (rouge), projection avec lissage (bleu)

14

Les types de segmentation : bloc, ligne, mot

Segmentation en ligne par projection des pixels



FIGURE - Segmentation par projection des pixels

14

Les types de segmentation : bloc, ligne, mot

Segmentation en ligne par projection des pixels

Regroupement de composantes connexes (avec une extraction de points d'intêrets, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)

Les types de segmentation : bloc, ligne, mot

Segmentation en ligne par projection des pixels

Regroupement de composantes connexes (avec une extraction de points d'intêrets, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)

Limites

- ⇒ Croisement entre les hampes et jambages de lignes connexes ;
- ⇒ Présence de filets potentiellement.
- ⇒ Solution DMOS envisagée

NORMALISATION DES IMAGES

⇒ Diminuer les caractéristiques liées aux différents scripteurs



FIGURE – Normalisation par identification des lignes de base et fixation des espacements

Limites

⇒ Écriture cursive et longiligne plus prononcée à certaines périodes

NORMALISATION DES IMAGES

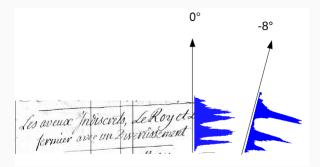


FIGURE – Correction de l'angle d'inclinaison des lignes par maximisation des projections de pixels

Limites

- ⇒ Écriture cursive et longiligne plus prononcée à certaines périodes
- ⇒ Beaucoup de lignes courbes dans les registres

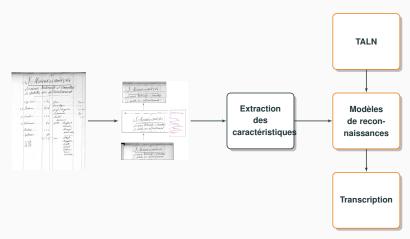


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures

EXTRACTION DE CARACTÉRISTIQUES

Caractéristiques géométriques et statistiques

Nombre de transition observée entre l'écriture et l'arrière-plan;

Nombre de pixels d'encre observés ;

Position des contours supérieurs et inférieurs dans la fenêtre ;

Moyenne des valeurs des pixels ;

Position du centre de gravité;

Position des lignes bases (ou références).

Caractéristiques directionnelles

SIFT : détection de points clés ;

HOG: histogrammes des gradients orientés.

Caractéristiques par AE, CAE et CNN

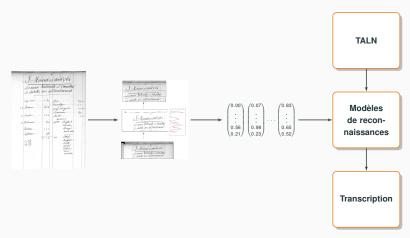


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures

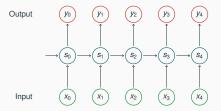


FIGURE – Réseau de neurones récurrents uni-directionnel

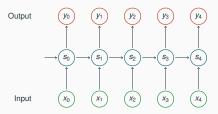


FIGURE – Réseau de neurones récurrents uni-directionnel

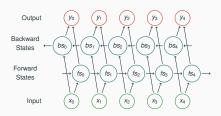


FIGURE – Réseau de neurones récurrents bi-directionnel

Limites

⇒ Vanishing gradient : perte du gradient sur le long terme

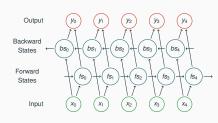


FIGURE – Réseau de neurones récurrents bi-directionnel

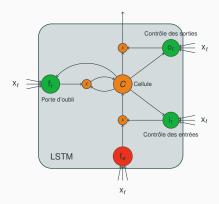


FIGURE – Cellule de type *Long* short-term memory

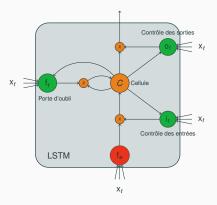


FIGURE – Cellule de type *Long* short-term memory

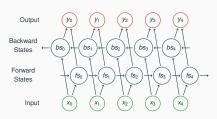


FIGURE – Réseau de neurones récurrents bidirectionnel utilisant les cellules LSTM

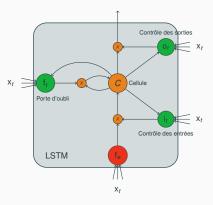


FIGURE – Cellule de type *Long* short-term memory

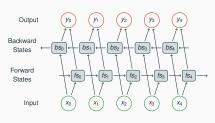


FIGURE - Réseau de neurones récurrents bidirectionnel utilisant les cellules LSTM

Créé pour des tâches de classifications temporels ⇒ problèmes d'étiquetages de séquences où l'alignement est inconnu entre l'entrée et la sortie du système

Pré-traitement des données d'entrée ou post-traitement des données en sortie du réseau : inutile

Prédit une séquence de caractères π pour une séquence d'entrée noté x

$$\mathbb{P}(\pi|\mathbf{x}) = \prod_{t=1}^{T} \mathbf{y}_{\pi_t}^t \tag{1}$$

où $y_{\pi_t}^t$ est la probabilité d'observer l'étiquette π à l'instant t

Caractéristiques

Unique couche de neurones de type Softmax

|L| neurones où un neuronne correspond à une classe

+1 neuronne "joker" appelé blank

Caractéristiques

Unique couche de neurones de type Softmax

|L| neurones où un neuronne correspond à une classe

+1 neuronne "joker" appelé blank

Apprentissage : algorithme forward-backward modifié pour intégrer le label blank dans la séquence de label attendue

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

$$cat \Rightarrow bl \ c \ bl \ a \ bl \ t \ bl$$

 $|l'| = 2 * |l| + 1$

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

cat
$$\Rightarrow$$
 bl c bl a bl t bl
 $|I'| = 2 * |I| + 1$

Calcul des variables :

$$lpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = l_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$

$$eta_t(oldsymbol{s}) = \sum_{\substack{\pi \in \mathbb{N}^t: \ \mathbb{B}(\pi_{t:T} = |_{oldsymbol{s}: t|t})}} \prod_{t'=t}^T y_{\pi_{t'}}^{t'}$$

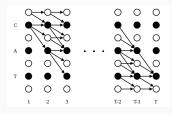


FIGURE - Treillis d'apprentissage pour le mot "cat" extrait de l'article de Graves et al

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

cat
$$\Rightarrow$$
 bl c bl a bl t bl
|I'| = 2 * |I| + 1

Calcul des variables :

$$\alpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = l_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$

$$\beta_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{t:T} = l_{s:|I|})}} \prod_{t'=t}^T y_{\pi_{t'}}^{t'}$$

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

$$cat \Rightarrow bl \ c \ bl \ a \ bl \ t \ bl$$

 $|I'| = 2 * |I| + 1$

Calcul des variables :

$$\alpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = I_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$
$$\beta_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{t:T} = I_{s:|I|})}} \prod_{t'=1}^T y_{\pi_{t'}}^{t'}$$

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

cat
$$\Rightarrow$$
 bl c bl a bl t bl
 $|I'| = 2 * |I| + 1$

Calcul des variables :

$$\alpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = l_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$
$$\beta_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{t:T} = l_{s:|t|})}} \prod_{t'=1}^T y_{\pi_{t'}}^{t'}$$

$$O = -\sum \log(\mathbb{P}(I|X))$$

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

$$cat \Rightarrow bl \ c \ bl \ a \ bl \ t \ bl$$

 $|I'| = 2 * |I| + 1$

Calcul des variables :

$$\alpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = l_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$
$$\beta_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{t:T} = l_{s:|t|})}} \prod_{t'=1}^T y_{\pi_{t'}}^{t'}$$

$$O = -\sum \log(\mathbb{P}(I|X))$$

$$\alpha_t(s)\beta_t(s) = \sum_{\substack{\pi \in \mathbb{B}^{-1}(I): t=1\\ \pi_t = I_s'}} \prod_{y_{\pi_t}^t} y_{\pi_t}^t = \sum_{\substack{\pi \in \mathbb{B}^{-1}(I):\\ \pi_t = I_s'}} p(\pi|x)$$

Apprentissage avec algorithme forward-backward modifié

Insertion du *blank* au début, à la fin et entre chaque caractère d'un label :

cat
$$\Rightarrow$$
 bl c bl a bl t bl
 $|I'| = 2 * |I| + 1$

Calcul des variables :

$$\alpha_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{1:t} = l_{1:s})}} \prod_{t'=1}^t y_{\pi_{t'}}^{t'}$$

$$\beta_t(s) = \sum_{\substack{\pi \in \mathbb{N}^t: \\ \mathbb{B}(\pi_{t:T} = l_{s:|I|})}} \prod_{t'=1}^T y_{\pi_{t'}}^{t'}$$

$$O = -\sum \log(\mathbb{P}(I|X))$$

$$\begin{split} \alpha_t(s)\beta_t(s) &= \sum_{\pi \in \mathbb{B}^{-1}(I): t=1} \prod_{y_{\pi_t}^t} y_{\pi_t}^t = \sum_{\pi \in \mathbb{B}^{-1}(I): \\ \pi_t = I_s'} p(\pi|x) \\ \mathbb{P}(\mathsf{I}|\mathsf{x}) &= \sum_{s=1}^{|I'|} \alpha_t(s)\beta_t(s) \end{split}$$

Caractéristiques

Unique couche de neurones de type Softmax

|L| neurones où un neuronne correspond à une classe

+1 neuronne "joker" appelé blank

Apprentissage: algorithme forward-backward modifié pour intégrer le label blank dans la séquence de label attendue, suivie du Maximum de vraissemblance pour permettre la backpropagation du gradient

Décodage : Meilleur chemin qui est la concaténation à chaque instant du neurone le plus actif ; Recherche de préfixe

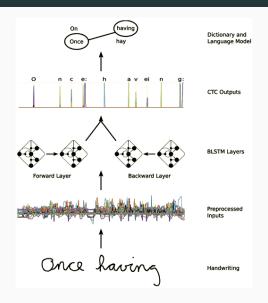


FIGURE - Système complet de reconnaissance d'écritures avec un réseau BLSTM et CTC extrait de l'article de Graves et al

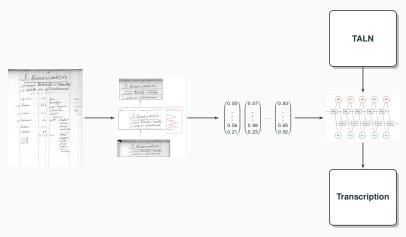


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures

TRAITEMENT AUTOMATIQUE DU LANGAGE: OUTILS

Traitement du langage

Dictionnaire

Lexique : mot associé à sa forme de base

Méthode probabiliste des n-grammes

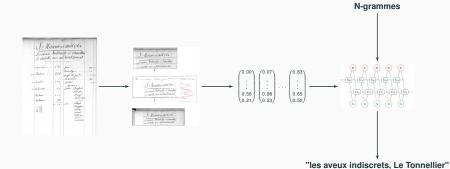


FIGURE – Présentation du processus complet dans le cadre de la reconnaissance d'écritures



BASE DE TRAVAIL AUTOUR DES CORPUS

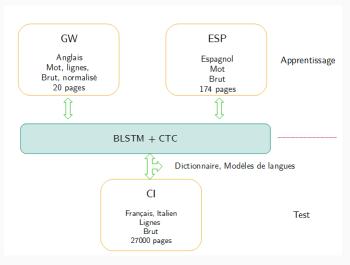


FIGURE – Utilisation des ensembles de données pour l'apprentissage et le test du système

PROBLÈMES IDENTIFIÉS

Transcription à partir du BLSTM+CTC : sujet aux erreurs

Vocabulaire fermé :

mot hors-vocabulaire variations de formes entre *Repertorio* et registres

Zone titre dans les registres :

plusieurs lignes

manque des mots

titres de ballets et d'opéras manquants – ex : "isle sonnante" de

Rabelais



CORPUS ESPOSALLES (ESP)

Au format xml ⇒ créer les images des lignes mots 174 pages de registres de mariage 5447 lignes 56378 imagettes de mots



FIGURE - Exemple d'un document



(a) Dijous



FIGURE - Imagettes des mots

CORPUS GEORGES WASHINGTON (GW)

Couple de fichiers (.tiff .gtp) ⇒ créer les images des mots sans normalisation

20 pages de lettres 2919 imagettes de mots

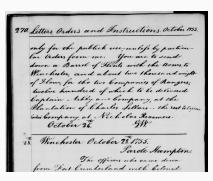


FIGURE – Exemple d'une page de GW (2700270)

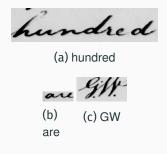


FIGURE – Imagettes des mots du registre 2700270

EXTRACTION DES FEATURES SUR LES IMAGES

Les caractéristiques statistiques (dans une colonne donnée) noté 4F:

profils haut et bas : premier et dernier pixels d'encre nombre de pixels d'encre

nombre de transitions entre l'encre et le fond

Les caractéristiques directionnelles : Histogramme des Gradients Orientés noté 8HOG, 64HOG

Sur GW normalisé

cell: (120,4) et (15,4)

block: 1,1



TEST SUR GW NORMALISÉ

Données : répartition aléatoire

train: 90% (4500)

validation : 5% (190)

test: 5% (200)

⇒ 5 samples : pour observer l'apprentissage des sorties du

réseau

Configuration:

type de données : mots normalisés

caractéristiques : 4F, 8HOG, 64HOG

epoch: 40

Istm: 100 nodes

output: 75 caractères + blank

décodage : le meilleur chemin

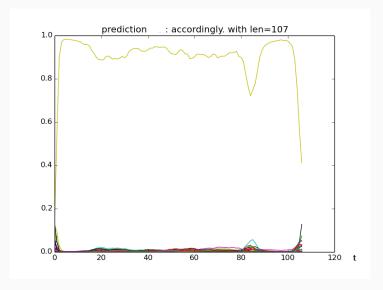


FIGURE - Courbe de prédiction du mot "accordingly." à 0 epoch

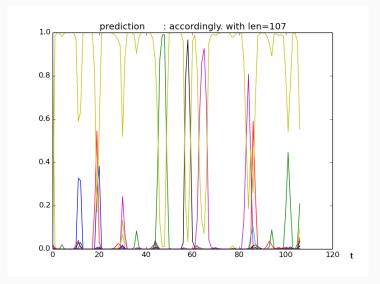


FIGURE - Courbe de prédiction du mot "accordingly." à 10 epoch

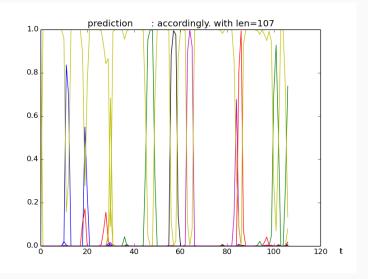


FIGURE - Courbe de prédiction du mot "accordingly." à 20 epoch

$$\text{WER} = \frac{\text{ins} + \text{supp} + \text{sub}}{\text{ins} + \text{supp} + \text{sub} + \text{corr}}$$

TABLE - Résultats obtenus et comparaison avec l'état de l'art

Méthode	Dataset	# feat	WER
BLSTM-CTC	IAM-OnDB	-	26%
BLSTM-CTC+ML	IAM-OnDB	-	20.4%
BLSTM	RIMES (fr,59203)	-	60.5%
BLSTM-CTCMMC	RIMES (fr.59203)	64 (pixels)	13.2%
BLSTM-CTCMMC	RIMES (fr,59203)	64 (HOG)	12.5%
BLSTM-CTC	GW (en,4893)	4 (4F)	14.7%
BLSTM-CTC	GW (en,4893)	8 (HOG)	47.39%
BLSTM-CTC	GW (en,4893)	64 (HOG)	13.5%
BLSTM-CTC	GW (en,4893)	64 (15 HOG)	33.4%

REFERENCES



Alex Graves, Santiago Fernández, Faustino Gomez, and Jürgen Schmidhuber.

Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks.

In Proceedings of the 23rd international conference on Machine learning, pages 369–376. ACM, 2006.



Alex Graves.

Sequence transduction with recurrent neural networks.

arXiv preprint arXiv :1211.3711, 2012.



Andreas Fischer, Markus Wüthrich, Marcus Liwicki, Volkmar Frinken, Horst Bunke, Gabriel Viehhauser, and Michael Stolz.

Automatic transcription of handwritten medieval documents.

In Virtual Systems and Multimedia, 2009. VSMM'09. 15th International Conference on, pages 137–142. IEEE, 2009.



Théodore Bluche, Hermann Ney, Jérôme Louradour, and Christopher Kermorvant. Framewise and ctc training of neural networks for handwriting recognition.

In Document Analysis and Recognition (ICDAR), 2015 13th International Conference on, pages 81–85. IEEE, 2015.



Nobuyuki Otsu.

A threshold selection method from gray-level histograms. *Automatica*, 11(285-296):23–27, 1975.



Kai Chen, Mathias Seuret, Marcus Liwicki, Jean Hennebert, and Rolf Ingold. Page segmentation of historical document images with convolutional autoencoders. In *Document Analysis and Recognition (ICDAR), 2015 13th International Conference on*, pages 1011–1015. IEEE, 2015.